ANALYSE COMPORTEMENTALE

de la Clientèle Retail

Clustering • Classification • Régression

Projet Machine Learning

présentée par : Rim Chaieb GI2S2

Tables des matiéres

01 Contexte & Dataset

02 Objectif du projet

03 Préparation et Problèmes des données

04 Exploration des données (EDA)

05 Feature Engineering

06 Modélisation

07 Évaluation et Optimisation des modèles

08 Déploiement (Flask)

Contexte

Entreprise e-commerce de cadeaux besoin de mieux comprendre les clients

- Objectifs business :
  - Personnalisation marketing
  - Réduction du churn
  - Optimisation du chiffre d'affaires

Objectif du projet

Construire un pipeline complet de Machine Learning :

- Exploration des données
- Prétraitement
- Feature engineering
- Modélisation
- Évaluation
- Déploiement (Flask)

Pipeline Machine Learning

1. nettoyage et préparation
2. feature engineering
3. nettoyage et préparation
4. encodage&normalisation
5. application du PCA
6. entraînement&évaluation des modèles
7. déploiement avec Flask

Exploration des données (EDA)

- Types de variables :
  - numériques (RFM, comportements)
  - Catégorielles (Région, Genre...)

Variable cible :

- Churn (0 = fidèle, 1 = parti)

L'analyse statistique à travers les histogrammes et boxplots permet d'observer la distribution des variablesCe projet s'appuie sur un jeu de données riche mais complexe, nécessitant un travail approfondi de préparation. La qualité des données brutes présentait plusieurs défis techniques qu'il a fallu surmonter pour garantir la fiabilité des modèles.

4372
Clients

52
Features initiales

33%
Taux de Churn

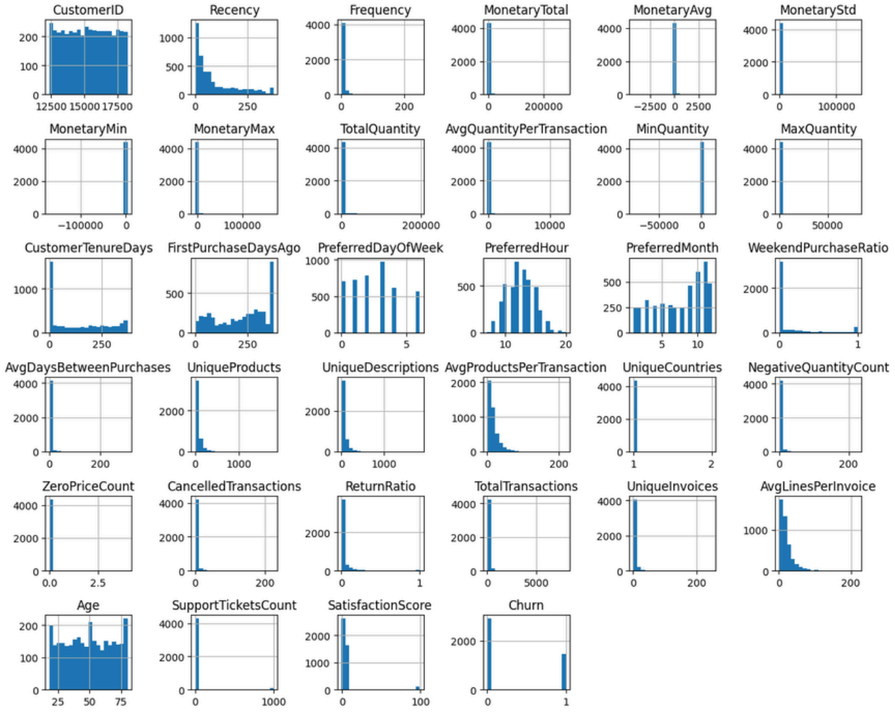

Problèmes des données

- Valeurs manquantes (ex: Age,AvgDaysBetweenPurchases)
- Valeurs aberrantes (SupportTickets, Satisfaction)
- Formats inconsistants (dates)
- Features inutiles (Newsletter)
- Déséquilibre des classes (churn)

Nettoyage des données

Améliorer la qualité des données pour garantir des modèles fiables

Étapes réalisées:

1. Gestion des valeurs manquantes
   - Médiane (robuste aux outliers)

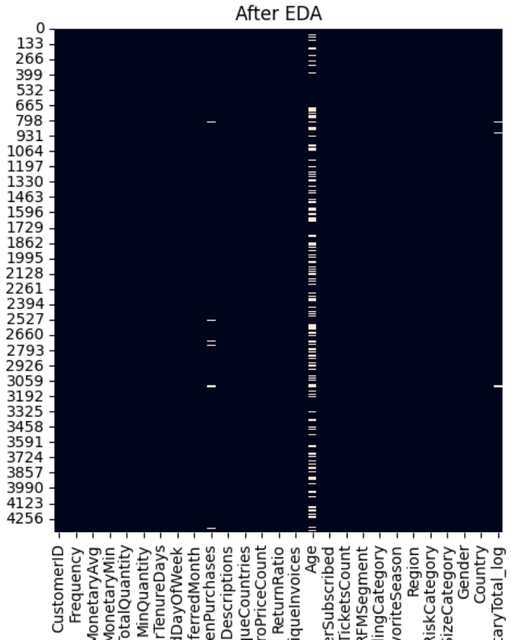

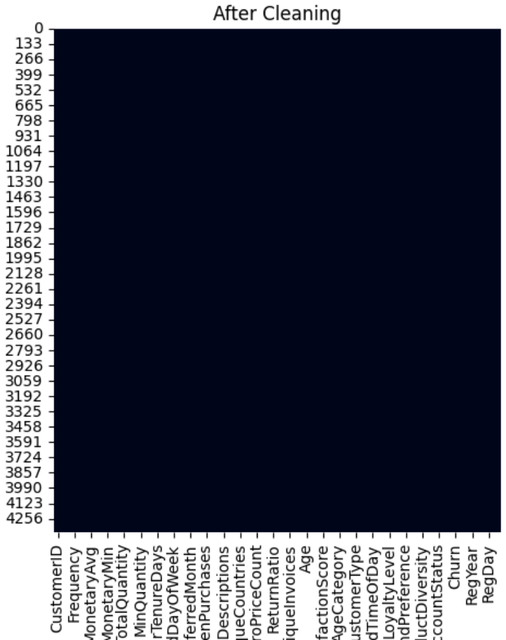

2. Correction des valeurs aberrantes (Outliers):

- Features : SupportTickets , Satisfaction
- Problèmes détectés :
  - Valeurs invalides : -1, 99, 999

=>Remplacement par NaN → puis médiane

3. Parsing des dates:

- Feature : RegistrationDate et LastLoginIP
- Problème :
  - Formats multiples ("12/03/10", "2010-03-12")

=> Extraction : Year ,Month ,Day ,Weekday

4. Suppression des features inutiles
Newsletter → constante
LastLoginIP → trop complexe
meme la colonne de RegistrationDate aprés l'extraction des nouvelle data .

Dataset prêt pour feature engineering et suppression corrélation

! Fit sur X_train uniquement (éviter data leakage)

Feature Engineering

L'objectif :permet de transformer les données brutes en variables plus pertinentes, capables de capturer des patterns cachés dans le comportement des clients pour booster la précision du modèle .

Créer des variables plus informatives que les données brutes

1. Comportement d'achat
MonetaryPerDay : Mesure l'intensité d'achat
2. Valeur panier moyen
AvgBasketValue : taille moyenne du panier => client VIP vs petit client
3. Fidélité client
TenureRatio : compare ancienneté vs activité récente => détecter churn
4.fréquence d'achat
purchaseintensity : fréquence d'achat dans le temps => client fidèle ou pas

Encodage, transformation log & normalisation

1. Transformations log pour réduire la skewness
Réduire l'impact des valeurs extrêmes et normaliser la distribution des variables
Certaines variables sont très asymétriques (skewed) :
    - monetarytotal
    - totalquantity
    - frequency

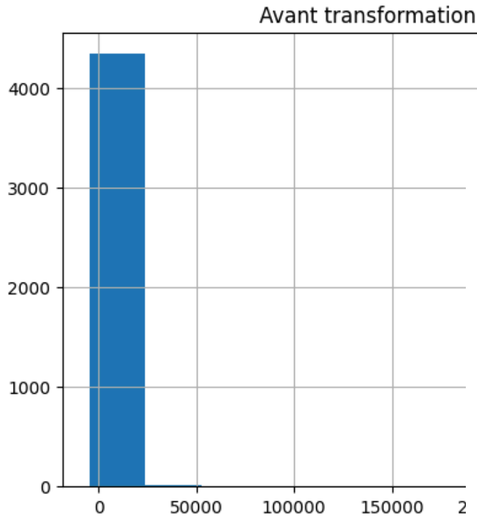

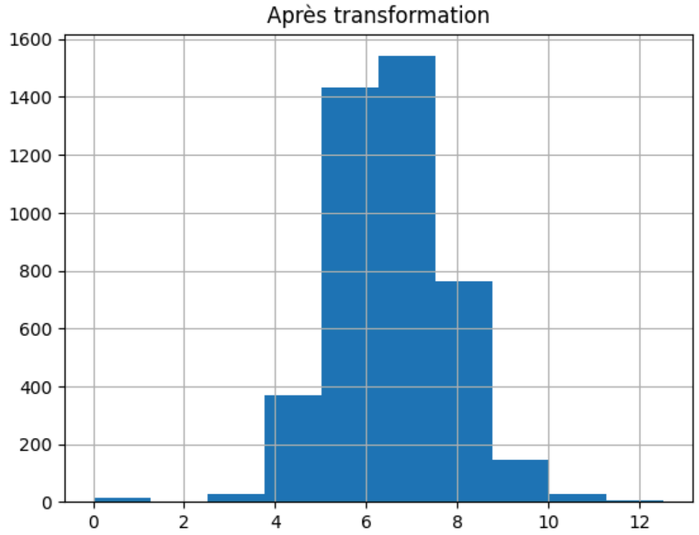

2.encodage :
Méthodes utilisées :

- One-Hot Encoding :
  - Gender, Region, CustomerType
- Ordinal Encoding :
  - LoyaltyLevel
  - SpendingCat

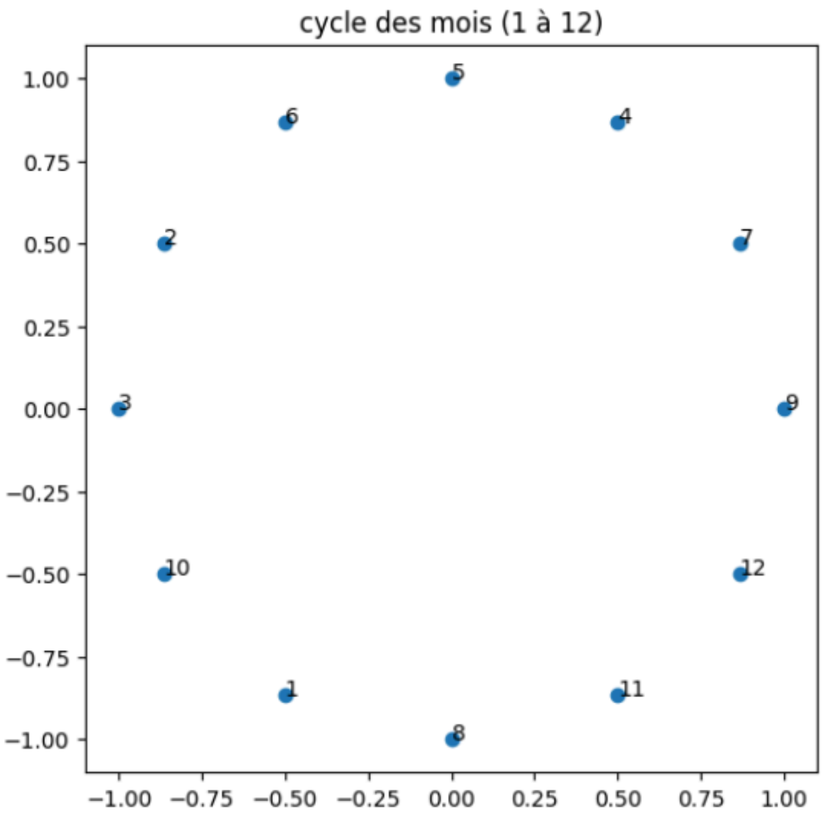

3.Normalisation
Pourquoi ?

- Les modèles comme :
  - Logistic Regression
  - KNN
  - SVM

  sont sensibles à l'échelle

```
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

⚠ **Fit uniquement sur X_train**
→ **Éviter le Data Leakage !**

Heatmap de Corrélation – Suppression des Redondances

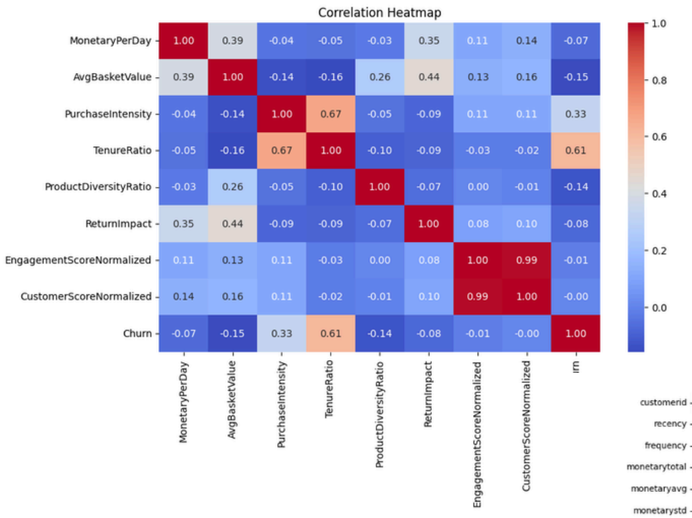

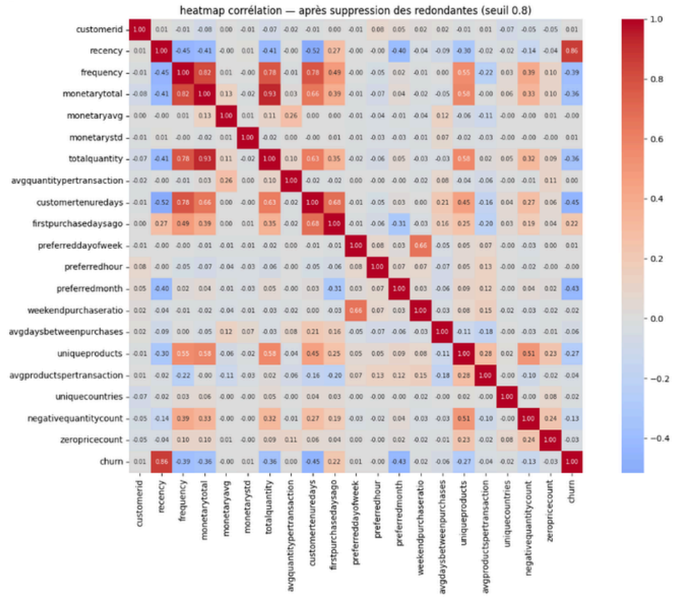

L'analyse de la heatmap de corrélation a permis d'identifier plusieurs paires de variables fortement corrélées (corrélation proche de 1 ou -1), traduisant une redondance d'information entre certaines features. Afin de réduire la multicolinéarité et d'éviter un sur-apprentissage des modèles, des variables ont été supprimées, notamment celles parfaitement ou fortement liées

Modélisation

Préparation : Train (80%) / Test (20%) → Scaling → PCA → SMOTE (équilibrage)

Prédire le churn client

1.Préparation des données

- Train/Test split
  - Train (80%) → pour entraîner le modèle
  - Test (20%) → pour évaluer
- Scaling
- PCA (Réduction de dimension)
  - Réduire le nombre de variables tout en gardant l'essentiel de l'information

=> Réduction des features initiales à seulement 48 composantes principales. Cette compression significative élimine la multicolinéarité et accélère considérablement les temps de calcul des modèles.

=>Conservation de 95% de la variance expliquée totale. Ce seuil optimal garantit que l'information discriminante est préservée tout en réduisant le bruit et améliorant la performance du clustering K-Means.

- **SMOTE** (Équilibrage des classes)

Générer de nouvelles données pour équilibrer les classes

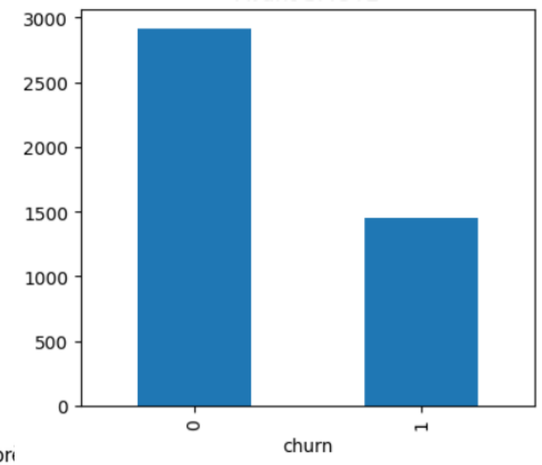

- Clustering : Segmenter les clients selon leur comportement

Méthode

- Algorithme non supervisé : KMeans
  - Regroupement basé sur la similarité

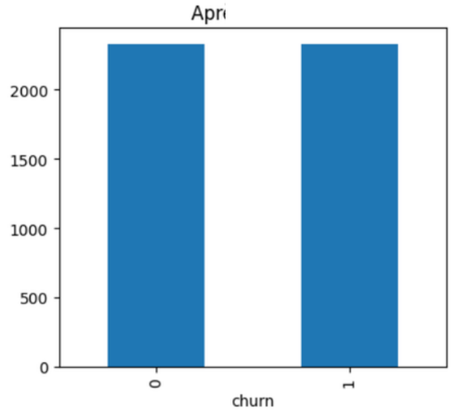

- Algorithme K-Means

Application sur les 48 composantes principales issues de la PCA. Donc K=4 déterminé par méthode du coude

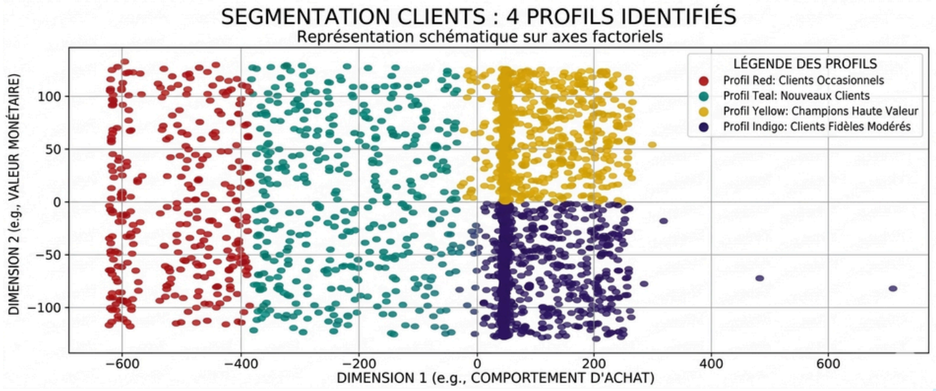

Modèles testés

- Logistic Regression
- Random Forest
- Random Forest + GridSearchCV

1. Phase initiale

⚠ Au depart Accuracy = 100% → TROP PARFAIT → Data Leakage détecté ! => modéle non_réel

2. Problème détecté

- présence de data leakage
- certaines colonnes trop corrélées avec la target :
  - CustomerType_Perdu
  - ChurnRiskCategory
  - AccountStatus_Closed

3. Solution appliquée : suppression des colonnes fuite

4.1 Résultats finaux pour la classification :

Modèle	Accuracy	Precision(churn)	Recall (churn)	F1-Score
Régression Logistique	76.1%	66%	67%	67%
Random Forest	77.8%	68%	68%	68%
Random Forest (Optimisé)	82.86%	73.9 %	74%	74.4%

Les hyperparamètres ont été optimisés avec GridSearchCV.
Le meilleur modèle utilise 200 arbres, une profondeur de 10, et un réglage adapté pour éviter l'overfitting.

Le modèle Random Forest Optimisé présente les meilleures performances avec une accuracy de 82.86%, une precision de 73.9%, un recall de 74.9% et un F1-Score de 74.4%. Ces résultats démontrent une amélioration significative par rapport aux modèles de base, permettant une meilleure prédiction du churn client.

4.2 Résultats finaux pour la regression— Estimation des dépenses clients:

Modèle	R^2	MAE (£)	RMSE (£)
Linear Regression	0.896	223	364
Random Forest Regressor	0.901	217	355

Le Random Forest donne les meilleurs résultats avec un R^2 de 0.90, ce qui signifie que le modèle explique 90% des dépenses des clients. Cela permet une estimation fiable du revenu futur.

Déploiement d'une application flask

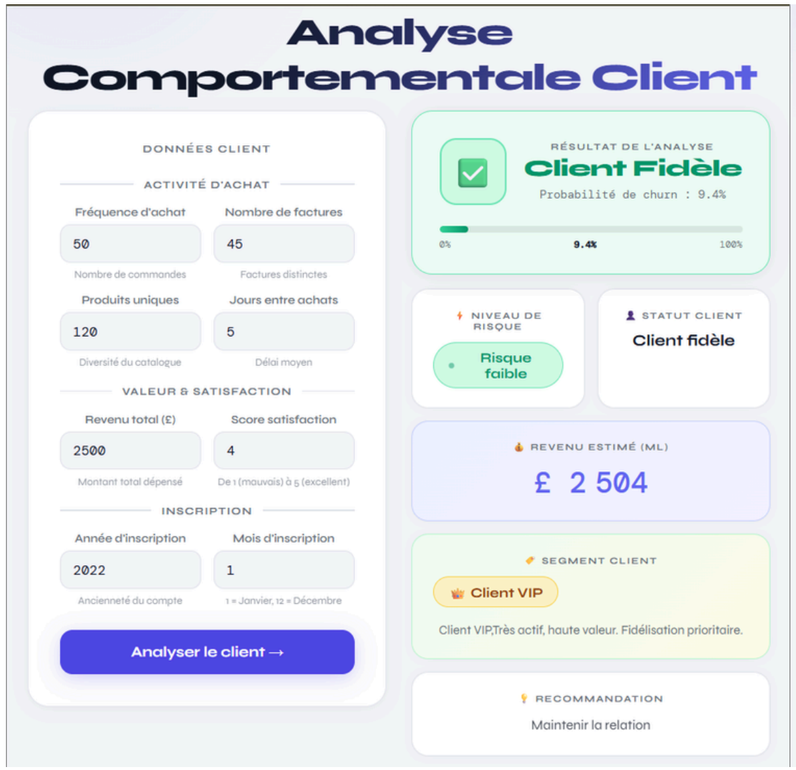

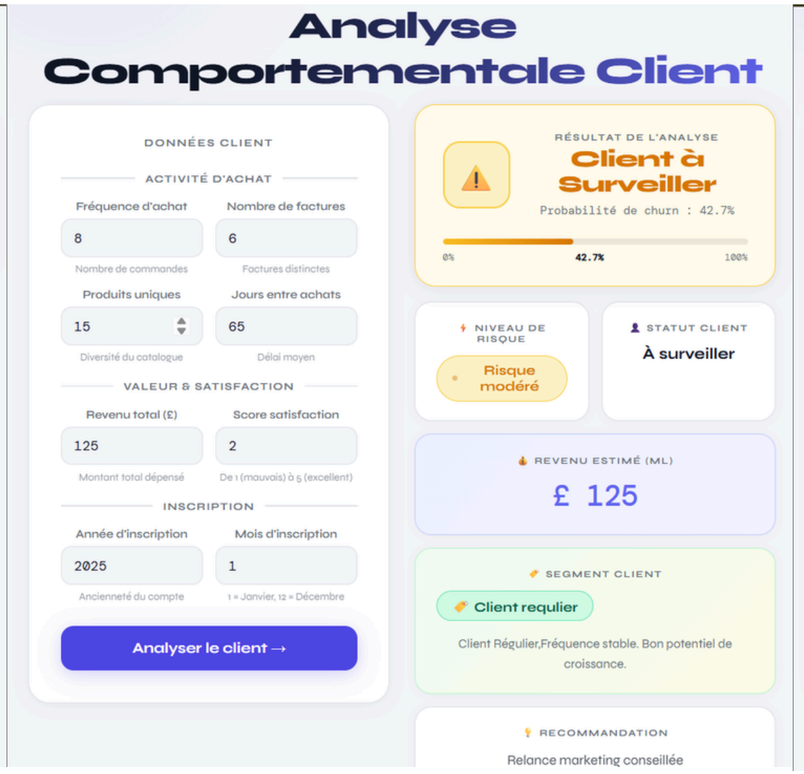

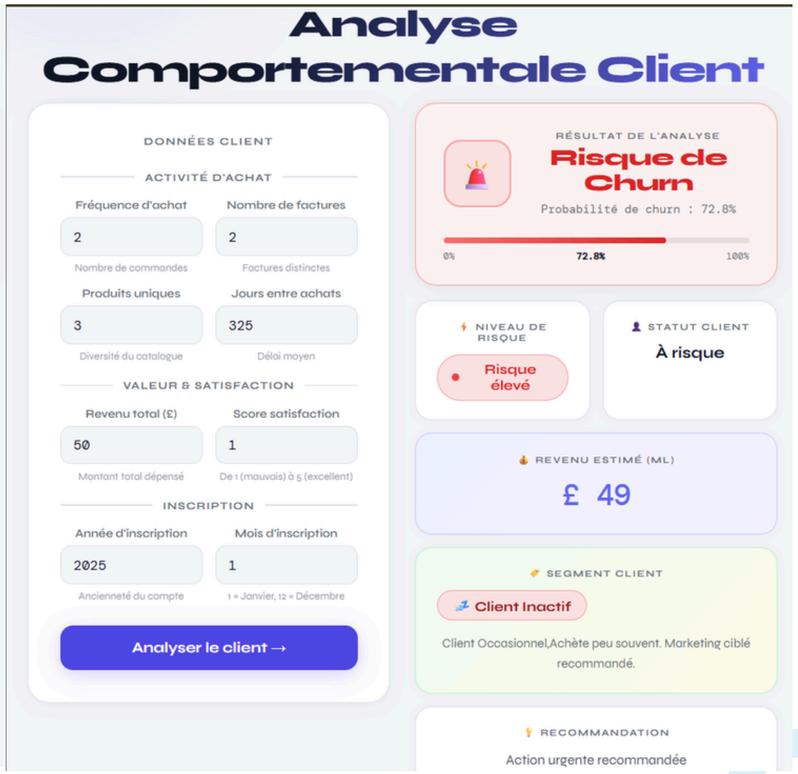

- Chargement des modéles necessaires pour la classification des nouveaux clients
- Prédiction en temps réel : cluster,churn,risk et revenu

CONCLUSION

Résultats clés

- Pipeline complet de ML réalisé
- Prédiction du churn (Accuracy 82.8%)
- Estimation des dépenses ($R^2 = 0.90$)
- Segmentation clients en 4 clusters

Apports du projet

- Meilleure compréhension du comportement client
- Aide à la décision marketing
- Optimisation du chiffre d'affaires

Limites & améliorations

- Données bruitées et imparfaites
- Modèles améliorables (XGBoost, Deep Learning)
- Possibilité d'ajouter plus de données

Perspectives

- Déploiement réel en entreprise
- Dashboard interactif (Power BI / Streamlit)
- Personnalisation marketing automatisée

MERCI POUR VOTRE ATTENTION